Relatório Trabalho Prático TP1

Teoria da Informação 2024/25

Francisco Carvalho Gouveia - 2023214517

Ricardo José Elvas Domingues - 2023215896

Rui Pedro Madeira Marques - 2023209756

Tiago Machado Teixeira – 2023224647

Conteúdo

Carregamento e construção dos dados 3
Representação gráfica do MPG em função das variáveis 3
Definição do alfabeto para os dados 4
Cálculo do número de ocorrências 4
Representação gráfica do número de ocorrências 4
Implementação binning para as variáveis 5
Cálculo da entropia teórica para as variáveis 5
Cálculo do número de bits por símbolo através da codificação de Huffman . 7
Cálculo dos coeficientes de correlação de Pearson 8
Cálculo da informação mútua entre MPG e as variáveis 10
Cálculo do MPG estimado 10

Carregamento e construção dos dados

Usamos o módulo *pandas* para carregar os dados do arquivo *CarDataset.xlsx*. Primeiro, com a função *read_excel*, extraímos as informações para a variável data. Por fim, criamos uma lista chamada *varNames* para armazenar os nomes das colunas.

Representação gráfica do MPG em função das variáveis

O gráfico foi obtido através de um ciclo for que percorre todas as colunas da informação contida na variável *data*, de seguida é criada uma matriz 3 x 2 para a visualização dos seis gráficos, são criados os gráficos, atribuímos os títulos de cada gráfico e, por fim atribuímos o título da variável analisada ao eixo x e o título de MPG ao y.

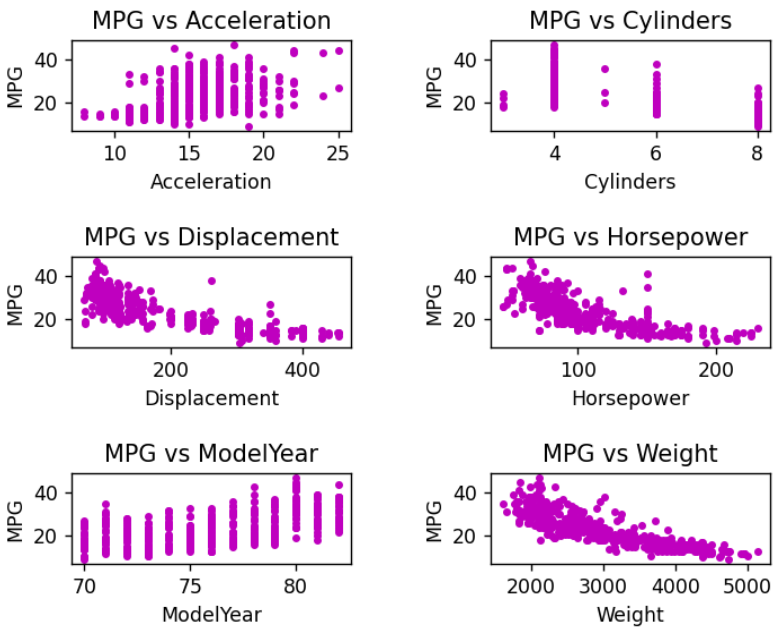

Figura 1

Entre os aspetos *"Acceleration"* e *"ModelYear"* é possível observar que à medida que estas aumentam o "MPG" também aumenta, ou seja, admitem uma relação de proporcionalidade direta entre si.

No entanto, com os restantes, *"Displacement"*, *"Cylinders"*, *"Horsepower"* e *"Weight"* verifica-se uma relação de proporcionalidade inversa, ou seja, quando estas aumentam o MPG diminui.

Definição do alfabeto para os dados

Com o intuito de definir o alfabeto mais apropriado para o pretendido, convertemos os dados da variável *data* através de uma nova variável *nova_data* para unit16. É inicializada uma nova variável *alfabeto_geral* que contém um array de inteiro de 0 até *2**n_bits,* sendo *n_bits* uma variável que armazena o número de bits de cada elemento do array.

Cálculo do número de ocorrências

Para calcular o número de ocorrências dos símbolos do alfabeto, é criada a função *contar_ocorrencias*. Nesta é inicializado um dicionário onde cada variável corresponde a uma chave e o número de ocorrências destas é inicializado a zero. Através de um ciclo for, percorremos as colunas da *data*, verificamos se a chave já existe no dicionário e incrementamos em um a sua contagem.

Representação gráfica do número de ocorrências

Com o objetivo de apresentar o número de ocorrências calculado na última alínea em gráficos de barras, foi criada a função

calcular_ocorrencias. Nesta é percorrido o dicionário criado na alínea anterior e armazenados os valores de ocorrência num array *ocor*.

É criado o gráfico onde o eixo x e y corresponde às chaves do dicionário e ao número de ocorrências, respetivamente. As barras são coloridas a vermelho, o eixo x tem como título o nome da variável, e o y intitula-se sempre como "contagem".

Implementação binning para as variáveis

É criada a função *binning* que divide os valores de uma coluna em intervalos predefinidos, substituindo cada valor pelo valor mais frequente dentro de seu intervalo.

Para isso, *binning* primeiro cria intervalos no alfabeto de valores da coluna, onde cada intervalo contém uma quantidade de símbolos definida através do parâmetro *num_simbolos*. Em seguida, para cada valor da coluna original, verifica a qual intervalo o valor pertence e substitui-o pelo valor mais frequente nesse intervalo, com base nas ocorrências previamente calculadas. Caso não haja valores com frequência positiva no intervalo, uma mensagem de aviso é exibida.

Cálculo da entropia teórica para as variáveis

É implementada a função *calculo_medio_bits*, que calcula a entropia em bits para avaliar a variabilidade de valores em cada coluna de dados, assim como a entropia média considerando todas as colunas.

Para cada coluna, é determinada a frequência normalizada de cada valor e calculada a entropia aplicando a fórmula de Shannon, que é $-\sum p(x) \log_2(p(x))$. Essa entropia é impressa como uma média em bits por coluna, indicando a incerteza ou variabilidade dos valores. Em seguida, é calculada a entropia global, tratando todas as colunas como uma

única sequência de dados. Este valor fornece uma visão da variabilidade total do conjunto de dados.

```
---------------------
Cálculo médio de bits:
--------------------
Média (entropia) para Acceleration: 3.4964235579
Média (entropia) para Cylinders: 1.5904356904
Média (entropia) para Displacement: 4.9412502273
Média (entropia) para Horsepower: 4.5365579116
Média (entropia) para ModelYear: 3.6906425112
Média (entropia) para Weight: 6.0741300339
Média (entropia) para MPG: 4.8357996223
Média total (entropia considerando todas as colunas juntas): 6.6629001286
```

Figura 2

A análise das médias de entropia para cada atributo revela uma variação significativa na incerteza associada a cada um. O atributo *Cylinders* apresenta a menor entropia (1,59), indicando baixa variabilidade e maior previsibilidade, possivelmente devido a um número limitado de valores distintos. Já *Weight* tem a entropia mais alta (6,07), sugerindo uma grande diversidade de valores e maior variabilidade nos dados.

A entropia total considerando todas as colunas juntas é de 6,66, valor superior ao de qualquer coluna individual. Esse aumento se deve à combinação das variabilidades de cada atributo, o que resulta em uma maior incerteza conjunta. Em resumo, alguns atributos possuem valores mais previsíveis, enquanto outros apresentam uma distribuição mais dispersa, o que pode ser útil para entender a variabilidade e estrutura dos dados, auxiliando em tarefas de compressão ou seleção de atributos.

Cálculo do número de bits por símbolo através da codificação de Huffman

A função *huffmaan* utiliza a codificação de Huffman para analisar a eficiência da representação dos dados. É calculado o comprimento médio e a variância dos comprimentos dos códigos de Huffman por coluna, assim como para o conjunto de dados completo.

Para cada coluna, é criado um *codec* de Huffman, que gera códigos binários para cada símbolo da coluna com base na frequência de ocorrência desses símbolos. Usando esses códigos, calcula-se a média ponderada do comprimento dos códigos *L_media*, que representa o número médio de bits necessários para codificar cada símbolo. A variância ponderada também é calculada, fornecendo uma medida da dispersão dos comprimentos de código.

Após realizar esses cálculos para cada coluna individualmente, a função repete o processo para os dados completos, tratando todas as colunas como uma sequência única.

```
----------------------
Codificação Huffmaan:
--------------------
Média ponderada para Acceleration: 3.5356265356 bits
Variância ponderada dos comprimentos: 0.8138413151

Média ponderada para Cylinders: 1.7297297297 bits
Variância ponderada dos comprimentos: 0.7131947672

Média ponderada para Displacement: 4.9803439803 bits
Variância ponderada dos comprimentos: 1.4394170807

Média ponderada para Horsepower: 4.5601965602 bits
Variância ponderada dos comprimentos: 1.2635753913

Média ponderada para ModelYear: 3.7272727273 bits
Variância ponderada dos comprimentos: 0.1983471074

Média ponderada para Weight: 6.1056511057 bits
Variância ponderada dos comprimentos: 0.8758157309

Média ponderada para MPG: 4.8697788698 bits
Variância ponderada dos comprimentos: 0.8847623590

Média ponderada (total): 6.6942786943 bits
Variância ponderada dos comprimentos (total): 2.579402156
```

Figura 3

Comparando com os dados de entropia anteriores, notamos que a média ponderada dos comprimentos na codificação de Huffman é ligeiramente superior e que os valores devem estar entre a entropia e a entropia acrescida a 1.

Para reduzir a variância, é possível otimizar a distribuição dos comprimentos de código, assegurando que símbolos mais frequentes tenham códigos de tamanhos mais uniformes. Outra forma é agrupar valores frequentes ou ajustar a base da codificação, o que pode ajudar a tornar os comprimentos de código mais homogêneos.

Reduzir a variância dos comprimentos é importante porque aumenta a eficiência de armazenamento e transmissão, facilita a decodificação e minimiza o desperdício de espaço. Uma menor variância significa comprimentos de código mais próximos da média, tornando a codificação mais eficiente e previsível.

Cálculo dos coeficientes de correlação de Pearson

A função *correlacao_pearson* calcula a correlação de Pearson entre cada variável em *varNames* e a coluna MPG do conjunto de dados. Para cada variável, calcula-se o coeficiente de correlação de Pearson com MPG, que indica o grau de associação linear entre elas.

Os resultados, apresentados para cada variável, ajudam a identificar quais variáveis possuem maior impacto linear sobre MPG, facilitando a análise de fatores relevantes.

```
---------------------
Cálculo da correlação de Pearson:
--------------------
Correlação de Pearson entre Acceleration e MPG: 0.4135853380757751
Correlação de Pearson entre Cylinders e MPG: -0.7760589899625305
Correlação de Pearson entre Displacement e MPG: -0.8043757174021732
Correlação de Pearson entre Horsepower e MPG: -0.7574852895591856
Correlação de Pearson entre ModelYear e MPG: 0.5872638852454328
Correlação de Pearson entre Weight e MPG: -0.8314322685415215

---------------------
Cálculo da informação mútua:
--------------------
Informação mútua entre MPG e Acceleration : 0.8720358370364725
Informação mútua entre MPG e Cylinders : 0.9621786410869264
Informação mútua entre MPG e Displacement : 2.1080086057732155
Informação mútua entre MPG e Horsepower : 1.7980222788914346
Informação mútua entre MPG e ModelYear : 1.0294236623155244
Informação mútua entre MPG e Weight : 2.6465941806351507
```

Figura 4

Os resultados da correlação de Pearson e da informação mútua entre MPG e outros atributos mostram diferentes aspetos da relação entre essas variáveis.

A correlação de Pearson mede a relação linear, com valores próximos de 1 ou -1 indicando fortes correlações positivas ou negativas, respetivamente. Observa-se uma correlação negativa entre MPG e *Cylinders*, *Displacement*, *Horsepower* e *Weight*, sendo mais forte com *Weight* (-0,83) e *Displacement* (-0,80). Isso sugere que, linearmente, quanto maiores esses valores, menor tende a ser o MPG. Em contraste, *ModelYear* apresenta uma correlação positiva com MPG (0,59), indicando que veículos mais recentes tendem a ter maior eficiência de combustível.

A informação mútua, por outro lado, mede a dependência geral entre variáveis, capturando relações lineares e não lineares. Os valores de informação mútua são mais altos, especialmente entre MPG e *Weight* (2,65) e *Displacement* (2,10), indicando uma dependência forte e possivelmente não linear entre essas variáveis e MPG.

Cálculo da informação mútua entre MPG e as variáveis

A função *calcular_informacao_mutua* calcula a informação mútua entre a variável MPG e uma variável específica do conjunto de dados, quantificando a dependência entre elas. A informação mútua mede o quanto conhecer o valor de uma variável reduz a incerteza sobre a outra, ou seja, o grau de informação compartilhada.

Na função são extraídas as colunas de MPG e da variável indicada, calculadas as probabilidades individuais para cada valor único de MPG e da variável e formata uma matriz de pares para calcular a distribuição conjunta dos valores e obter a probabilidade conjunta de cada par.

Cálculo do MPG estimado

A função *estimar_mpg* utiliza uma fórmula de regressão linear com coeficientes fixos para estimar o consumo de combustível (MPG). A função realiza três previsões distintas para avaliar o impacto de diferentes variáveis na precisão da estimativa.

Primeiro, a função converte os dados em um array e calcula as médias de Acceleration e Weight para uso nas previsões. Em seguida são realizadas três previsões, na primeira são utilizados os valores reais das variáveis, na segunda *Acceleration* é substituída pela sua média, e na terceira substitui-se *Weight* também pela sua média.

Para cada previsão, a função calcula o erro absoluto médio (MAE) e o erro quadrático médio (RMSE), ambos indicadores da precisão das estimativas em relação aos valores reais. O MAE mede o erro médio sem considerar sua direção, enquanto o RMSE amplifica os erros maiores.

```
---------------------
Estimar MPG:
--------------------
MAE: 2.819224078624079
RMSE: 3.7349633608

Substituindo Acc pelo seu valor médio
MAE: 2.857694373041794
RMSE: 3.7443008464

Substituindo Weight pelo seu valor médio
MAE: 4.80805123363256
RMSE: 5.9984796353
```

Figura 5

Os resultados mostram que, ao estimar o MPG, a substituição de variáveis por suas médias impacta a precisão do modelo de formas diferentes:

Sem substituições: MAE de 2.82 e RMSE de 3.73.

Substituindo *Acceleration* pela média: Pequeno aumento nos erros (MAE: 2.86, RMSE: 3.74), indicando que *Acceleration* tem influência menor na estimativa.

Substituindo *Weight* pela média: Grande aumento nos erros (MAE: 4.81, RMSE: 5.99), mostrando que *Weight* é crucial para a precisão do modelo.

Conclusão: A variabilidade de *Weight* é muito importante para estimar o MPG com precisão, enquanto *Acceleration* tem impacto menor.